Báo cáo phân tích dữ liệu và Machine Learning MovieLens 10M

Từ dữ liệu đánh giá phim đến chiến lược nội dung theo nhóm khán giả

Thông tin	Nội dung
Bộ dữ liệu	MovieLens 10M của GroupLens Research
Quy mô	10.000.054 lượt đánh giá | 10.681 phim | 69.878 người dùng có rating
Công cụ	MySQL 8.0 | KNIME Analytics Platform | Power BI
Mô hình	K Means để phân khúc khán giả | Logistic Regression để dự đoán khả năng thích phim
Ngày hoàn thiện	25 tháng 10 năm 2026

Tóm tắt dành cho người mới

Dự án này trả lời một câu hỏi thực tế: nền tảng phim nên giới thiệu nội dung nào cho từng kiểu khán giả. Dữ liệu không chứa thông tin cá nhân hay lịch sử xem; dữ liệu chỉ cho biết ai đã chấm phim nào, chấm bao nhiêu sao và vào thời điểm nào. Vì vậy, kết quả được hiểu là mức độ phù hợp về sở thích rating, không phải xác suất xem phim, mua gói hay tạo doanh thu.

Quy trình giữ nguyên toàn bộ 10.000.054 dòng rating hợp lệ, chuẩn hóa cấu trúc dữ liệu, chia quá khứ và tương lai theo thời gian, tạo đặc trưng chỉ từ phần quá khứ rồi áp dụng hai mô hình dễ giải thích. K Means tạo bốn nhóm hành vi; Logistic Regression ước lượng xác suất một rating đạt từ 4 sao trở lên. Trên 76.633 dòng TEST đủ điều kiện, mô hình đạt Accuracy 69,26 phần trăm và ROC AUC 75,83 phần trăm. Phạm vi bao phủ chỉ 5,11 phần trăm của TEST nên kết quả phù hợp nhất cho người dùng và phim đã có lịch sử trong TRAIN.

Từ khóa *MovieLens, làm sạch dữ liệu, phân khúc khán giả, K Means, Logistic Regression, MySQL, KNIME, Power BI*

1 Bài toán và kết luận chính

Nếu chỉ quảng bá phim theo bảng xếp hạng phổ biến, mọi người dùng sẽ thấy gần như cùng một danh sách. Cách làm đó bỏ qua khác biệt về mức độ hoạt động, thể loại yêu thích và xu hướng chấm điểm. Dự án xây dựng một hệ thống hỗ trợ quyết định để Content Programming and Personalization Manager có thể lựa chọn phim cần quảng bá, duy trì, giảm ưu tiên hoặc đưa vào thử nghiệm.

Positive engagement được định nghĩa là rating lớn hơn hoặc bằng 4,0. Đây là một quy ước đo sở thích. Một dòng có rating 4 hoặc 5 được gắn nhãn thích; các mức còn lại được gắn nhãn không thích. Cách định nghĩa đơn giản này cho phép xây dựng bài toán phân loại nhị phân và giải thích kết quả bằng xác suất.

Các câu hỏi ra quyết định

Câu hỏi	Dữ liệu trả lời	Kết quả sử dụng
Người dùng khác nhau như thế nào	Mức độ hoạt động, điểm trung bình, tỷ lệ rating tích cực và sở thích thể loại	Hồ sơ bốn phân khúc
Có thể gom người dùng thành nhóm nào	Khoảng cách giữa các hồ sơ hành vi đã chuẩn hóa	K Means và chỉ số silhouette
Một người có khả năng thích một phim hay không	Lịch sử người dùng, lịch sử phim, phân khúc và thể loại	Xác suất từ Logistic Regression
Nội dung nào nên được thử nghiệm quảng bá	Xác suất dự đoán, tỷ lệ thực tế, độ phổ biến và số quan sát	Content Opportunity Matrix

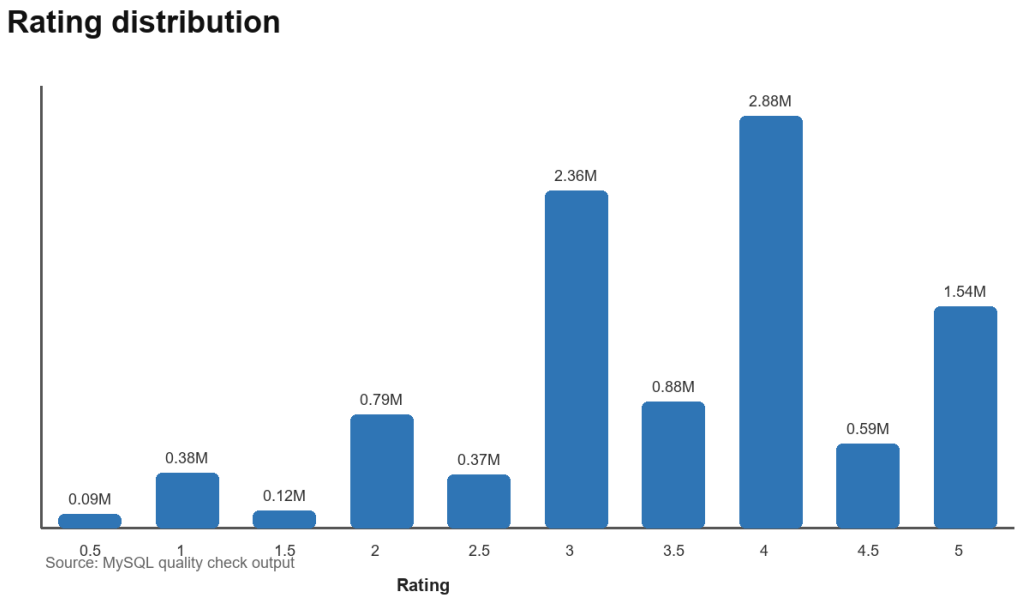
Kết luận quan trọng nhất là mô hình có ích như một bộ lọc ưu tiên thử nghiệm, không phải cơ chế tự động quyết định cho toàn bộ nền tảng. Khả năng bao phủ còn thấp và dữ liệu đã cũ, nên mọi đề xuất quảng bá cần được kiểm chứng bằng A B test với dữ liệu xem thực tế.

2 Bộ dữ liệu MovieLens 10M

MovieLens 10M là bộ dữ liệu nghiên cứu công khai do GroupLens phát hành vào tháng 1 năm 2009. Người dùng được ẩn danh. Bộ dữ liệu không có tên, email, tuổi, giới tính hay vị trí địa lý. Mỗi người dùng xuất hiện trong bảng ratings có ít nhất 20 lượt đánh giá, vì vậy mẫu nghiêng về người dùng hoạt động tương đối tích cực.

Thành phần	Số dòng	Trường chính	Ý nghĩa
ratings	10.000.054	user id, movie id, rating, timestamp	Sự kiện một người dùng chấm một phim từ 0,5 đến 5 sao
movies	10.681	movie id, title, genres	Danh mục phim và danh sách thể loại phân tách bằng dấu gạch đứng
tags	95.580	user id, movie id, tag, timestamp	Từ khóa tự do do người dùng gắn cho phim
movie genres	21.564	movie id, genre	Bảng đã chuẩn hóa để một phim có thể liên kết với nhiều thể loại
rating users	69.878	user id	Số người dùng thực sự có ít nhất một rating

Tài liệu gốc ghi 71.567 người dùng vì con số đó bao gồm cả người dùng chỉ xuất hiện trong tệp tags. Báo cáo sử dụng 69.878 khi nói về người dùng rating. Các timestamp trải từ ngày 9 tháng 1 năm 1995 đến ngày 5 tháng 1 năm 2009.



Hình 1 Phân bố 10.000.054 lượt đánh giá trong MovieLens 10M

Điểm 4,0 xuất hiện nhiều nhất với 2.875.850 lượt. Điểm trung bình toàn bộ dữ liệu là 3,512 và 50,06 phần trăm rating đạt từ 4,0 trở lên. Tỷ lệ hai lớp khá cân bằng ở toàn bộ dữ liệu, nhưng tỷ lệ này thay đổi sau khi chỉ giữ các dòng đủ lịch sử TRAIN.

3 Hiểu đúng về làm sạch dữ liệu

Làm sạch dữ liệu không đồng nghĩa với xóa thật nhiều dòng. Mục tiêu là bảo đảm mỗi trường có ý nghĩa rõ ràng, mỗi khóa liên kết đúng, giá trị nằm trong phạm vi hợp lệ và mọi biến dùng cho mô hình được tạo theo một quy trình có thể chạy lại. Trong dự án này, dữ liệu gốc có chất lượng cấu trúc tốt nên không cần xóa hay điền thay bất kỳ dòng rating nào.

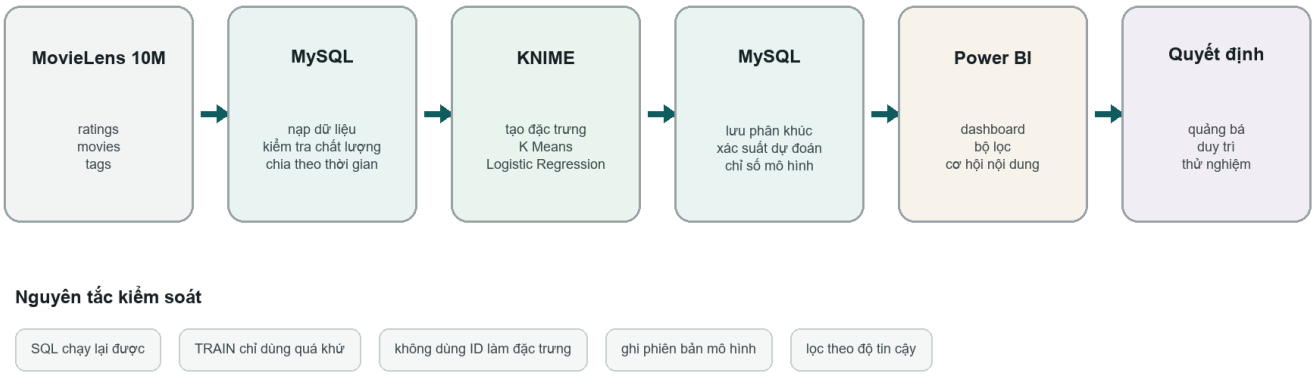
Kiểm tra	Trước xử lý	Sau xử lý	Cách xử lý và ý nghĩa
Tổng số rating	10.000.054	10.000.054	Giữ nguyên vì mọi dòng đều hợp lệ
Rating hoặc tag thiếu phim tham chiếu	0	0	Khóa liên kết không có bản ghi mồ côi
Rating hoặc timestamp không hợp lệ	0	0	Giá trị nằm trong thang điểm và thời gian cho phép
Cặp người dùng và phim bị trùng	0	0	Không cần loại bỏ bản ghi trùng
Người dùng dưới 20 rating	0	0	Phù hợp điều kiện tối thiểu của dataset
Phim có ít nhất một rating	10.677 trên 10.681	10.677 trên 10.681	Giữ bốn phim chưa có rating như bản ghi danh mục hợp lệ

Các bước làm sạch và chuẩn hóa

1. Nạp ba tệp gốc vào MySQL với kiểu dữ liệu rõ ràng cho ID, rating và timestamp.
2. Thiết lập khóa chính và index để ngăn lỗi định danh và tăng tốc truy vấn trên 10 triệu dòng.
3. Kiểm tra giá trị thiếu, bản ghi mồ côi, rating ngoài thang 0,5 đến 5, timestamp không hợp lệ và cặp user movie trùng.
4. Tách chuỗi genres thành bảng movie genres, giúp một phim có nhiều thể loại mà vẫn truy vấn đúng.
5. Sắp xếp theo thời gian và chia TRAIN VALID TEST theo tỷ lệ 70 15 15.
6. Tạo thống kê người dùng, phim và thể loại chỉ từ TRAIN; với dòng TRAIN dùng leave one out để rating hiện tại không tự giải thích chính nó.
7. Trong KNIME, xử lý giá trị thiếu của đặc trưng, hạn chế ảnh hưởng của ngoại lệ và chuẩn hóa thang đo trước khi huấn luyện.
8. Ghi phân khúc, dự đoán, metric, phiên bản mô hình và thời gian chạy trở lại MySQL.

4 Pipeline dữ liệu từ đầu đến cuối

Từ dữ liệu thô đến quyết định nội dung



Hình 2 Kiến trúc dữ liệu và luồng xử lý của dự án

MySQL là nơi lưu trữ có kiểm soát cho dữ liệu gốc, bảng đặc trưng và kết quả mô hình. KNIME đọc trực tiếp từ MySQL, thực hiện tiền xử lý và machine learning, sau đó ghi kết quả trở lại các bảng user segments, rating predictions và model metrics. Power BI chỉ đọc các view đã tổng hợp thay vì tải toàn bộ 10 triệu dòng, giúp dashboard nhẹ và giữ được nguồn gốc dữ liệu.

Tầng	Ví dụ	Vai trò
Dữ liệu gốc	ratings, movies, tags	Bảo toàn dữ liệu được phát hành
Dữ liệu chuẩn hóa	movie genres, rating split	Tách thể loại và định nghĩa các khoảng thời gian
Đặc trưng	train user stats, train movie stats, ml rating features	Biến lịch sử thành các cột số mà mô hình có thể sử dụng
Kết quả mô hình	user segments, rating predictions, model metrics	Lưu nhóm, xác suất, nhãn và chỉ số đánh giá
Báo cáo	dashboard views	Cung cấp dữ liệu nhỏ gọn cho Power BI

Điểm mạnh của kiến trúc này là khả năng truy vết. Một con số trên dashboard có thể lần ngược về view MySQL, bảng kết quả KNIME và cuối cùng là dữ liệu gốc. Model version ngăn việc trộn kết quả từ nhiều lần chạy khác nhau.

5 Vì sao phải chia TRAIN VALID và TEST

Machine learning cần được kiểm tra bằng dữ liệu mà mô hình chưa nhìn thấy. Có thể hình dung TRAIN là bộ bài tập dùng để học, VALID là bài thi thử để điều chỉnh và TEST là bài thi cuối cùng. Nếu đưa đáp án TEST vào quá trình học, kết quả sẽ đẹp giả tạo và không phản ánh khả năng dự đoán tương lai.

Phần	Số dòng	Khoảng thời gian	Mục đích
TRAIN	7.000.042	09 01 1995 đến 02 04 2005	Tạo lịch sử và huấn luyện mô hình
VALID	1.500.006	02 04 2005 đến 28 12 2006	Kiểm tra lựa chọn mô hình và ngưỡng
TEST	1.500.006	28 12 2006 đến 05 01 2009	Đánh giá cuối cùng trên giai đoạn tương lai

Bốn biện pháp chống rò rỉ dữ liệu

- Chia theo thời gian thay vì xáo trộn ngẫu nhiên để mô phỏng việc dự đoán tương lai từ quá khứ.
- Mọi thống kê lịch sử của người dùng, phim và thể loại chỉ được tính từ TRAIN.
- Đối với dòng TRAIN, leave one out loại rating hiện tại khỏi giá trị trung bình dùng làm đặc trưng.
- Quy tắc điền thiếu và chuẩn hóa được học trên TRAIN rồi giữ nguyên khi áp dụng cho VALID và TEST.

user id và movie id chỉ là mã định danh nên không được dùng như các con số có thứ tự. Nếu cho mô hình học trực tiếp rằng user 100 lớn hơn user 20, mô hình sẽ tạo ra quan hệ giả không có ý nghĩa kinh doanh.

Warm start và phạm vi bao phủ

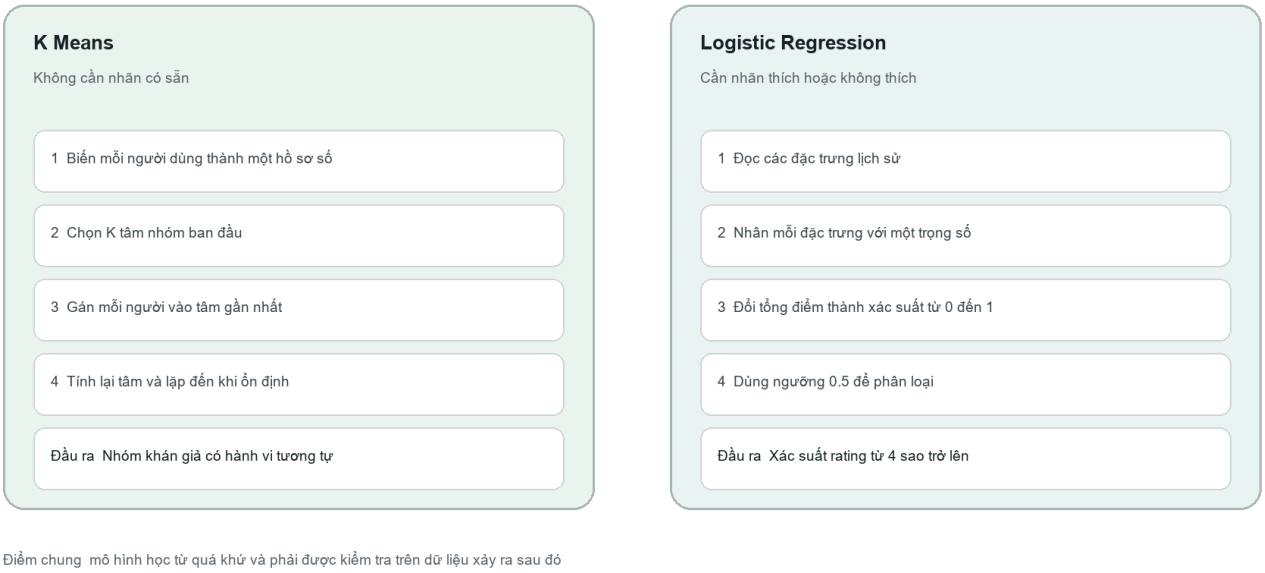
Một dòng chỉ đủ điều kiện dự đoán khi cả người dùng và phim đã có lịch sử trong TRAIN. Đây gọi là warm start. Quy tắc này bảo vệ ý nghĩa của đặc trưng nhưng làm số dòng TEST đủ điều kiện giảm còn 76.633 trên 1.500.006, tương đương 5,11 phần trăm. Với người dùng hoặc phim mới hoàn toàn, hệ thống cần fallback như danh sách phổ biến, biên tập viên hoặc mô hình cold start khác.

6 Machine Learning cho người mới bắt đầu

Machine learning là cách để máy tính học một quy luật từ nhiều ví dụ thay vì con người viết sẵn từng điều kiện. Mỗi hàng dữ liệu là một ví dụ. Các cột mô tả ví dụ được gọi là đặc trưng. Kết quả cần dự đoán được gọi là mục tiêu hoặc nhãn. Mô hình là công thức được điều chỉnh trong quá trình học để biến đặc trưng thành đầu ra.

Khái niệm	Trong dự án	Cách hiểu đơn giản
Quan sát	Một người dùng chấm một phim tại một thời điểm	Một ví dụ để mô hình học hoặc kiểm tra
Đặc trưng	Điểm trung bình quá khứ, mức độ hoạt động, lịch sử phim, phân khúc, thể loại	Các tín hiệu có trước thời điểm dự đoán
Nhãn	1 nếu rating từ 4 sao trở lên, ngược lại là 0	Đáp án đúng của bài toán phân loại
Mô hình	K Means và Logistic Regression	Quy tắc được học từ dữ liệu
Dự đoán	Xác suất thích phim và nhãn thích không thích	Đầu ra dùng để xếp hạng hoặc lọc

Hai mô hình giải quyết hai câu hỏi khác nhau



Hình 3 Vai trò khác nhau của K Means và Logistic Regression

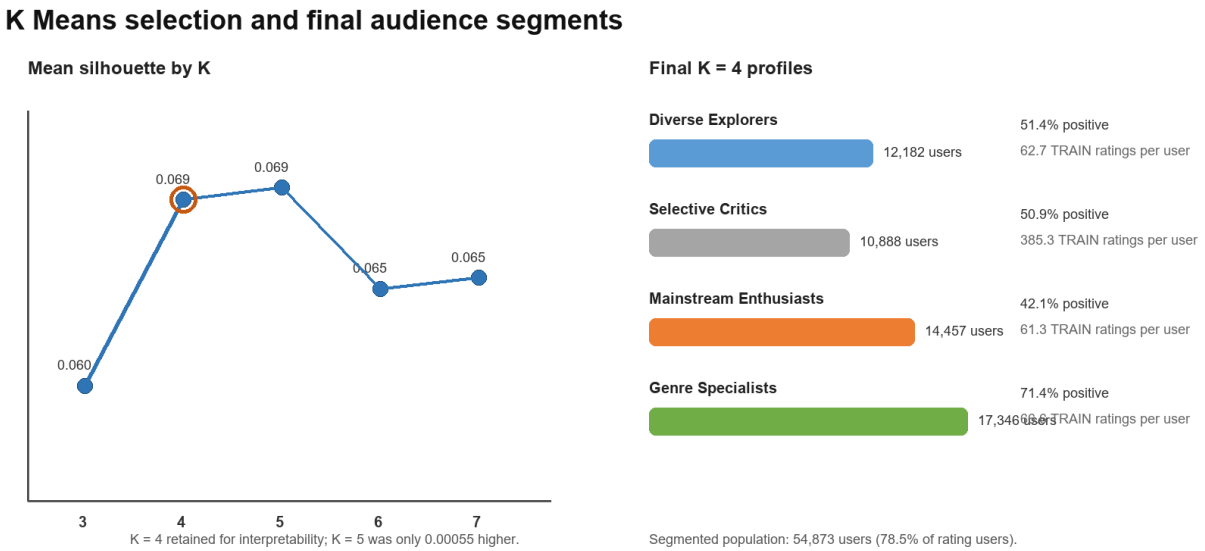
Hai mô hình được chọn vì dễ giải thích, chạy tốt trong KNIME, phù hợp với dữ liệu dạng bảng và cho phép kiểm tra rõ từng bước. Một mô hình phức tạp hơn không tự động tốt hơn nếu khó truy vết, không cải thiện trên TEST hoặc không phù hợp với mức độ bao phủ hiện tại.

7 K Means dùng để phân khúc khán giả

K Means là mô hình học không giám sát. Không có sẵn cột cho biết ai thuộc nhóm nào. Mô hình nhìn vào hồ sơ số của từng người dùng, đo khoảng cách và tìm các cụm sao cho người trong cùng cụm giống nhau hơn người ở cụm khác. Trước khi đo khoảng cách, các cột phải được chuẩn hóa; nếu không, cột có giá trị số lớn sẽ lấn át các cột còn lại.

Đặc trưng phân khúc gồm mức độ hoạt động, tuổi đời lịch sử rating, điểm trung bình, tỷ lệ rating tích cực và mức yêu thích tương đối theo thể loại. Mức yêu thích tương đối so sánh điểm của một thể loại với mức chấm điểm chung của chính người dùng, giúp phân biệt một người vốn chấm cao với một người thực sự thiên về thể loại đó.

K	Silhouette trung bình	Diễn giải
3	0,060209	Ít nhóm hơn nhưng độ tách thấp
4	0,068639	Được chọn vì cân bằng giữa khả năng giải thích và độ tách
5	0,069188	Chỉ cao hơn K bằng 4 khoảng 0,00055
6	0,064601	Kém hơn lựa chọn 4 nhóm
7	0,065112	Kém hơn lựa chọn 4 nhóm



Hình 4 So sánh K và quy mô bốn phân khúc cuối cùng

Phân khúc	Người dùng	Tỷ lệ tích cực	Cách hiểu hành vi
Diverse Explorers	12.182	51,38 phần trăm	Thiên tương đối về thriller, action và mystery
Selective Critics	10.888	50,88 phần trăm	Hoạt động nhiều nhất và có lịch sử dài nhất
Mainstream Enthusiasts	14.457	42,06 phần trăm	Thiên tương đối về family và animation
Genre Specialists	17.346	71,43 phần trăm	Nhóm lớn nhất và có xu hướng chấm tích cực cao nhất

Silhouette tuyệt đối còn thấp, nghĩa là ranh giới giữa các nhóm bị chồng lấn. Do đó, tên nhóm là nhãn diễn giải hành vi, không phải phân loại con người cố định và càng không phải thông tin nhân khẩu học.

8 Logistic Regression dự đoán khả năng thích phim

Logistic Regression là mô hình phân loại có giám sát. Mô hình học từ các ví dụ có đáp án thích hoặc không thích. Mỗi đặc trưng nhận một trọng số. Các tín hiệu được cộng lại thành một điểm, sau đó hàm logistic chuyển điểm này thành xác suất từ 0 đến 1. Ví dụ, xác suất 0,72 được hiểu là mô hình đánh giá tín hiệu tích cực mạnh hơn mức trung bình; nó không bảo đảm 72 phần trăm người dùng sẽ xem phim.

Những tín hiệu mô hình sử dụng

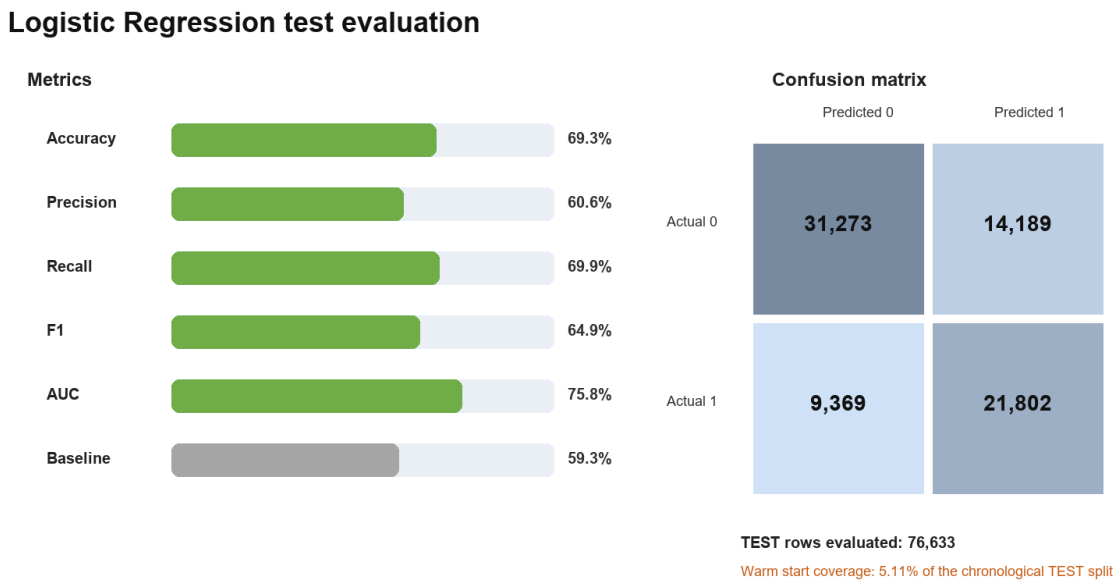
- Lịch sử người dùng như điểm trung bình, tỷ lệ rating tích cực và số rating trong TRAIN.
- Lịch sử phim như điểm trung bình, tỷ lệ tích cực và mức độ phổ biến trong TRAIN.
- Phân khúc K Means của người dùng và ngữ cảnh thể loại của phim.
- Các biến đã xử lý thiếu và chuẩn hóa bằng tham số học từ TRAIN.

Vì sao chọn Logistic Regression

Bài toán có hai lớp rõ ràng, dữ liệu là bảng số, stakeholder cần xác suất và cần hiểu hướng tác động của đặc trưng. Logistic Regression đáp ứng cả bốn yêu cầu, có baseline minh bạch và triển khai ổn định trong KNIME. Mô hình cũng phù hợp làm mốc chuẩn trước khi thử các thuật toán phức tạp hơn.

Bước	Điều xảy ra	Ý nghĩa
Huấn luyện	Tìm bộ trọng số giúp xác suất khớp nhãn TRAIN	Mô hình học quy luật từ quá khứ
VALID	Kiểm tra mô hình và ngưỡng 0,5	Hạn chế điều chỉnh trực tiếp trên TEST
TEST	Áp dụng nguyên quy trình lên giai đoạn sau	Đo khả năng tổng quát ngoài thời gian huấn luyện
Write back	Lưu actual, predicted, probability, split và version	Cho phép SQL và Power BI kiểm tra lại kết quả

9 Đánh giá mô hình và cách đọc chỉ số



Hình 5 Kết quả Logistic Regression trên tập TEST đủ điều kiện

Chỉ số	Kết quả	Giải thích cho người mới
Accuracy	69,26 phần trăm	Trong 100 dự đoán, khoảng 69 dự đoán đúng
Majority baseline	59,32 phần trăm	Nếu luôn đoán lớp phổ biến nhất thì đúng khoảng 59 lần
Precision	60,58 phần trăm	Trong các trường hợp mô hình dự đoán thích, khoảng 61 phần trăm thực sự thích
Recall	69,94 phần trăm	Trong các trường hợp thực sự thích, mô hình tìm được khoảng 70 phần trăm
F1	64,92 phần trăm	Điểm cân bằng giữa precision và recall
ROC AUC	75,83 phần trăm	Khả năng xếp một trường hợp tích cực cao hơn một trường hợp tiêu cực

Confusion matrix gồm 31.273 true negative, 14.189 false positive, 9.369 false negative và 21.802 true positive. False positive là trường hợp mô hình dự đoán thích nhưng người dùng thực tế không cho rating tích cực; trong bài toán quảng bá, đây là rủi ro làm lãng phí vị trí hiển thị. False negative là nội dung người dùng có thể thích nhưng mô hình bỏ sót; đây là rủi ro mất cơ hội khám phá.

Accuracy cao hơn baseline 9,93 điểm phần trăm và ROC AUC cho thấy khả năng xếp hạng hữu ích. Tuy nhiên, các chỉ số chỉ mô tả 76.633 dòng TEST warm start chứ không đại diện cho toàn bộ 1.500.006 dòng TEST. Vì vậy, khi trình bày hiệu quả mô hình luôn phải đặt metric cạnh coverage 5,11 phần trăm.

10 Từ kết quả mô hình đến quyết định nội dung

Power BI kết hợp bốn loại bằng chứng: xác suất dự đoán, tỷ lệ rating tích cực quan sát được, độ phổ biến trong TRAIN và support trong TEST. Xác suất cao nhưng support thấp chưa đủ để hành động. Tương tự, một phim phổ biến không nhất thiết phù hợp với mọi phân khúc.

Hành động đề xuất	Bằng chứng	Cách triển khai an toàn
Thử nghiệm Hotel Rwanda và My Neighbor Totoro cho Selective Critics	Hotel Rwanda support 108, dự đoán 76,72 phần trăm, thực tế 77,78 phần trăm. My Neighbor Totoro support 58, dự đoán 74,87 phần trăm, thực tế 74,14 phần trăm.	Đưa vào một discovery row thử nghiệm và so sánh với trải nghiệm hiện tại
Bổ sung City of God và Oldboy vào nhóm ứng viên	City of God support 60, dự đoán 71,66 phần trăm. Oldboy support 52, dự đoán 69,94 phần trăm.	Giới hạn ở người dùng warm start và theo dõi theo từng phim
Giảm ưu tiên mặc định một số phim phổ biến trong Selective Critics	Home Alone, Star Wars Episode I, Twister và The Mask có support trên 50 nhưng tỷ lệ tích cực thực tế thấp	Không gỡ khỏi danh mục; chỉ giảm vị trí trong trải nghiệm của phân khúc này
Dùng fallback khi không đủ lịch sử	Coverage TEST của classifier chỉ 5,11 phần trăm	Dùng danh sách phổ biến hoặc biên tập cho cold start và theo dõi coverage như KPI

Thiết kế kiểm chứng tiếp theo

Người dùng đủ điều kiện nên được chia ngẫu nhiên vào nhóm trải nghiệm hiện tại và nhóm nhận danh sách theo phân khúc. Hai nhóm cần có cùng vị trí hiển thị, thời gian thử nghiệm và số lượt tiếp xúc. Khi có dữ liệu hiện đại hơn, các chỉ số chính nên gồm click through, play start, completion, rating sau khi xem và doanh thu hoặc chi phí bản quyền nếu phù hợp.

The Incredibles nên được dùng như một trường hợp chẩn đoán. Mô hình dự đoán 74,45 phần trăm nhưng tỷ lệ thực tế chỉ 60,75 phần trăm trên 107 quan sát. Khoảng lệch này có thể phản ánh calibration chưa tốt, bối cảnh phim hoặc thay đổi theo thời gian.

11 Hạn chế và nguyên tắc sử dụng có trách nhiệm

- Dữ liệu kết thúc vào tháng 1 năm 2009 nên không phản ánh đầy đủ catalog và hành vi streaming hiện nay.
- Rating chỉ xuất hiện sau khi người dùng chủ động chấm. Không rating không đồng nghĩa với không thích.
- Không có impression, lượt xem, watch time, click, completion, subscription, doanh thu hay chi phí bản quyền.
- Mọi rating user có ít nhất 20 rating nên mẫu thiên về người dùng hoạt động tích cực.
- Coverage của classifier thấp; kết quả không nên áp dụng trực tiếp cho cold start.
- Silhouette thấp cho thấy phân khúc chồng lấn; tên nhóm chỉ là mô tả hành vi tương đối.
- Title level support đủ mạnh chủ yếu tập trung ở Selective Critics; các phân khúc khác cần thêm dữ liệu.
- Mô hình chưa được kiểm tra calibration và chưa chứng minh tác động nhân quả của chiến dịch quảng bá.

Nguyên tắc sử dụng

Nên làm	Không nên làm
Dùng xác suất để ưu tiên danh sách thử nghiệm	Coi xác suất là bảo đảm người dùng sẽ xem
Luôn hiển thị metric cùng coverage và support	Chỉ trình bày Accuracy mà bỏ qua phạm vi áp dụng
Giữ fallback cho người dùng và phim mới	Ép mô hình dự đoán khi không có lịch sử
Theo dõi phiên bản, thời gian chạy và biến đổi dữ liệu	Trộn kết quả từ nhiều model version
Đánh giá bằng A B test trước khi mở rộng	Suy luận trực tiếp thành doanh thu hoặc tác động nhân quả

Hướng cải tiến hợp lý gồm thêm đặc trưng cold start, kiểm tra calibration, đánh giá theo ranking metrics, rolling temporal validation và dữ liệu exposure. Khi có dữ liệu vận hành, mục tiêu nên chuyển từ rating proxy sang hành vi phù hợp hơn với quyết định kinh doanh.

12 Kết luận

Dự án đã triển khai đầy đủ chuỗi Dataset đến MySQL đến KNIME đến MySQL write back đến Power BI và quyết định nội dung. Dữ liệu được kiểm tra chất lượng, giữ nguyên các tương tác hợp lệ, chuẩn hóa thể loại và chia theo thời gian trước khi tạo đặc trưng. Hai mô hình được chọn vì phù hợp với hai câu hỏi khác nhau và có thể giải thích cho stakeholder không chuyên.

K Means tạo bốn lăng kính hành vi để so sánh người dùng, nhưng không tạo ra các nhóm tách biệt tuyệt đối. Logistic Regression cải thiện Accuracy 9,93 điểm phần trăm so với majority baseline và đạt ROC AUC 75,83 phần trăm trên phần TEST đủ điều kiện. Giá trị thực tế của hệ thống nằm ở khả năng tạo danh sách ứng viên minh bạch cho controlled experiment, không nằm ở việc tự động hóa hoàn toàn quyết định quảng bá.

Quyết định phù hợp nhất ở thời điểm hiện tại là thử nghiệm có kiểm soát với nhóm Selective Critics, theo dõi kết quả trên dữ liệu xem hiện đại và giữ cơ chế fallback cho phần lớn trường hợp chưa đủ lịch sử. Cách tiếp cận này tận dụng được tín hiệu từ mô hình mà vẫn tôn trọng giới hạn của dataset và phạm vi bằng chứng.

Thuật ngữ ngắn

Thuật ngữ	Giải thích
Feature	Cột thông tin đầu vào mà mô hình sử dụng
Target hoặc label	Kết quả đúng mà mô hình cần học
Training	Quá trình điều chỉnh mô hình bằng dữ liệu TRAIN
Inference	Dùng mô hình đã học để tạo dự đoán mới
Leakage	Vô tình để thông tin tương lai hoặc đáp án lọt vào dữ liệu học
Coverage	Tỷ lệ dữ liệu mà mô hình có đủ thông tin để dự đoán
Support	Số quan sát đứng sau một tỷ lệ hoặc một kết luận
Warm start	Người dùng và phim đã có lịch sử trước thời điểm dự đoán

Tài liệu tham khảo

[1] GroupLens Research. MovieLens 10M Dataset and README. 2009. https://grouplens.org/datasets/movielens/10m/ và https://files.grouplens.org/datasets/movielens/ml-10m-README.html

[2] F. M. Harper và J. A. Konstan. The MovieLens Datasets History and Context. ACM Transactions on Interactive Intelligent Systems, 2015. doi 10.1145/2827872

[3] S. P. Lloyd. Least Squares Quantization in PCM. IEEE Transactions on Information Theory, 1982. doi 10.1109/TIT.1982.1056489

[4] D. W. Hosmer, S. Lemeshow và R. X. Sturdivant. Applied Logistic Regression. Wiley, 2013

[5] T. Fawcett. An Introduction to ROC Analysis. Pattern Recognition Letters, 2006. doi 10.1016/j.patrec.2005.10.010

[6] G. James, D. Witten, T. Hastie và R. Tibshirani. An Introduction to Statistical Learning. Springer, 2021

Tái tạo kết quả

9. Tải MovieLens 10M từ GroupLens và kiểm tra ba tệp movies, ratings và tags.
10. Chạy các script 01 đến 05 trong python sql scripts để tạo schema, nạp dữ liệu, kiểm tra chất lượng, chia tập và tạo feature TRAIN.
11. Mở workflow KNIME audience segmentation, giữ K bằng 4 và ghi user segments về MySQL.
12. Chạy bước 06 để tạo ml rating features, sau đó chạy workflow Logistic Regression và ghi predictions cùng metrics.
13. Chạy bước 07 và refresh Power BI để kiểm tra dashboard views, model version, split dates và metric.